

UNIVERSITATEA BABEȘ-BOLYAI CLUJ-NAPOCA
FACULTATEA DE MATEMATICĂ ȘI INFORMATICĂ
SPECIALIZAREA INFORMATICĂ ROMÂNĂ

LUCRARE DE LICENȚĂ

**Aplicabilitatea modelelor AI de
estimare a adâncimii monocular în
detectia și evitarea obstacolelor**

**Conducător științific
Alexandru Manole**

*Absolvent
Ștefan - Lucian Grămadă*

2026

ABSTRACT

Această lucrare prezintă proiectarea și implementarea unui sistem de asistență pentru persoanele cu deficiență de vedere, menit să faciliteze navigarea independentă prin evitarea obstacolelor, axat pe un echilibru optim între acuratețe și accesibilitate financiară. Motivația proiectului derivă din nevoia de a oferi o soluție tehnologică performantă la un cost redus, facilitând astfel accesul la scară largă. Implementarea propusă utilizează unitatea de procesare Raspberry Pi 5 (8GB) împreună cu acceleratorul hardware AI HAT+. Această configurație susține execuția unui model monocular de tip DepthAnythingV3, capabil să estimeze adâncimea dintr-un flux video captat de o singură cameră.

Cuprins

1	Introducere	1
2	Lucrări Conexe	3
2.1	Calibrarea Camerelor și Anularea Distorsiunilor	3
2.2	Estimarea Adâncimilor cu Ajutorul Modelelor AI	4
2.3	Filtrarea Planului de Mers	5
2.4	Optimizarea Traiectoriilor	5
3	Metodologie	6
3.1	Arhitectura Generală	6
3.2	Caracteristicile Dispozitivelor Hardware Folosite	6
3.3	Calibrarea Camerei	7
3.4	Modelul Monocular de Estimare a Adâncimii	9
3.4.1	Depth Anything 3 (Platformă NVIDIA)	9
3.4.2	Depth Anything 2 ViT-S (Platformă Raspberry Pi)	10
3.5	Detecția Solului	10
3.5.1	Proiecția Inversă și Eșantionarea Punctelor Seed	11
3.5.2	Estimarea Planului prin RANSAC Vectorizat	11
3.5.3	Netezirea Temporală și Construirea Măștii	12
3.6	Detecția Drumului de Cost Minim	12
3.6.1	Determinarea Punctelor de Start și de Sfârșit	12
3.6.2	Algoritmul A* cu Conectivitate 8-Direcțională	13
4	Arhitectura Aplicației	14
4.1	Prezentare Generală	14
4.2	Principii de Proiectare Utilizate	14
4.2.1	Separarea Responsabilităților	14
4.2.2	Programare Orientată pe Obiecte	15
4.2.3	Configurație Tipizată	15
4.2.4	Comunicare Asincronă prin Semnale Qt	15
4.2.5	Inversiunea Dependențelor la Nivel de Backend	15

4.3	Arhitectura pe Straturi	16
4.3.1	Stratul de Prezenta-re (GUI)	16
4.3.2	Stratul de Orchestrare (Pipeline)	16
4.3.3	Stratul de Procesare (Core)	17
4.3.4	Stratul de Infrastructură	17
4.4	Diagrama Straturilor	18
4.5	Fluxul de Date	18
5	Rezultate	20
5.1	Calibrarea Camerei	20
5.2	Aproximarea Adâncimii	21
5.3	Detecția Planului	21
5.4	Determinarea Drumului de Cost Minim	21
5.5	Latență	21
5.6	Lumină Abundentă vs. Redusă	21
6	Direcții viitoare și Concluzii	22
	Bibliografie	23

Capitolul 1

Introducere

Conform raportului oficial al Organizației Mondiale a Sănătății [Wor19], aproximativ 2,2 miliarde de oameni trăiesc cu o formă de deficiență de vedere, dintre care cel puțin 1 miliard au o deficiență care ar fi putut fi prevenită sau care nu a fost încă tratată. Impactul funcțional este cel mai sever în rândul celor 43,3 milioane de persoane care suferă de orbire totală și al celor 295 de milioane cu deficiențe moderate până la severe (MSVI) [B⁺21]. Din perspectivă clinică, nevoia de asistență pentru deplasare devine universală odată ce acuitatea vizuală scade sub pragul de 3/60.

În ceea ce privește mecanismele de sprijin, deși utilizarea câinilor-ghid este considerată în literatura de reabilitare drept „standardul de aur” pentru fluiditatea mișcării, accesul global rămâne extrem de scăzut. Datele furnizate de International Guide Dog Federation [Int23] relevă existența a doar aproximativ 30.000 de câini activi la nivel mondial, ceea ce înseamnă că mai puțin de 0,1% din populația care ar avea nevoie clinică de un astfel de sprijin beneficiază efectiv de el. Această disparitate este accentuată de barierele economice, costul de antrenament al unui singur exemplar fiind estimat între 40.000\$ și 60.000\$ [S⁺18]. În acest context, majoritatea persoanelor cu deficiențe de vedere rămân dependente fie de bastonul alb (utilizat de aproximativ 33,8% din populația vizată), fie de asistența umană directă [S⁺21].

O evoluție tehnologică recentă, cu un impact semnificativ asupra pieței dispozitivelor portabile (*wearable technology*), este reprezentată de ascensiunea ochelarilor inteligente (*Smart Glasses*). Această categorie de dispozitive a fost popularizată recent prin parteneriate strategice, precum cel dintre Meta și Ray-Ban, care au integrat senzori optici performanți în accesorii de uz cotidian. Din punct de vedere tehnic, prezența camerei video pe aceste dispozitive permite captarea și procesarea fluxului vizual în timp real, oferind astfel o platformă potențială pentru sisteme de asistență computațională.

Motivată de nevoia critică de independență a persoanelor cu deficiențe severe de vedere și valorificând accesibilitatea actuală a tehnologiei de tip *Smart Glasses*, prezenta lucrare propune dezvoltarea unui sistem compact și eficient din punct de

vedere al costurilor. Obiectivul principal al sistemului este de a sprijini utilizatorul în detectarea și evitarea obstacolelor, facilitând astfel o mobilitate mai sigură și mai autonomă.

Structura lucrării este organizată după cum urmează: Capitolul următor trece în revistă literatura de specialitate ce au stat la baza creionării sistemului descris în lucrare. Ulterior, este prezentată arhitectura hardware a sistemului propus, urmată de analiza metodologiei de dezvoltare și a dificultăților tehnice întâmpinate. În final, lucrarea sintetizează performanțele obținute și propune direcții viitoare de cercetare în secțiunea de concluzii.

Capitolul 2

Lucrări Conexе

2.1 Calibrarea Camerelor și Anularea Distorsiunilor

Fundamentul oricărei analize metrice dintr-o imagine este stabilit prin calibrarea camerei. În lucrarea sa de referință, Zhang [Zha00] propune o tehnică flexibilă care a democratizat accesul la viziunea 3D prin eliminarea necesității unor aparate de calibrare costisitoare. Autorul demonstrează că utilizarea unui model plan (checkerboard) observat din cel puțin două orientări diferite este suficientă pentru a determina parametrii intrinseci și extrinseci ai camerei. Metoda se bazează pe calculul homografiei între planul modelului și proiecția sa în imagine, urmată de o rafinare neliniară prin criteriul verosimilității maxime care ia în considerare și distorsiunile radiale ale lentilei. Această abordare a transformat calibrarea dintr-un proces restrictiv de laborator într-o procedură aplicabilă în scenarii de utilizare reală.

Camera este modelată prin modelul pinhole standard, în care relația dintre un punct 3D M și proiecția sa în imagine m este:

$$s\tilde{m} = A \begin{bmatrix} R & t \end{bmatrix} \tilde{M} \quad (2.1)$$

unde s este un factor de scală arbitrar, $\tilde{m}$ și $\tilde{M}$ reprezintă coordonatele omogene ale punctului din imagine și respectiv din spațiul 3D, iar $R \in \mathbb{R}^{3 \times 3}$ și $t \in \mathbb{R}^3$ sunt parametrii extrinseci — matricea de rotație și vectorul de translație — care descriu poziția și orientarea camerei față de sistemul de coordonate al lumii. A este matricea intrinsecă a camerei:

$$A = \begin{bmatrix} \alpha & \gamma & u_0 \\ 0 & \beta & v_0 \\ 0 & 0 & 1 \end{bmatrix} \quad (2.2)$$

unde α și β sunt lungimile focale exprimate în pixeli pe axele orizontală și verticală, (u_0, v_0) este punctul principal reprezentând intersecția axei optice cu planul

imaginii, iar γ descrie oblicitatea axelor imaginii — neglijabilă în cazul camerelor digitale moderne.

Calibrarea estimează matricea A și coeficienții de distorsiune radială prin minimizarea erorii de reproiecție pe un set de imagini ale unui șablon de tip tablă de șah cu dimensiuni cunoscute. Soluția constă dintr-o estimare inițială în formă închisă, rafinată ulterior prin algoritmul Levenberg-Marquardt [Zha00].

Parametrii obținuți sunt utilizați în două etape ale procesării. În primul rând, fiecare cadru este rectificat geometric pentru a elimina distorsiunile radiale ale obiectivului, asigurând consistența cu modelul pinhole. În al doilea rând, lungimea focală medie $f = (\alpha + \beta)/2$ este utilizată pentru conversia ieșirii modelului de adâncime în metri, conform formulei [LCL⁺25]:

$$d_{\text{metric}} = \frac{f \cdot d_{\text{raw}}}{300} \quad (2.3)$$

unde d_{raw} reprezintă valoarea brută estimată de model, iar constanta 300 provine din transformarea spațiului canonic al camerei utilizată în antrenarea modelului [LCL⁺25]. În absența calibrării, lungimea focală este estimată presupunând un câmp vizual orizontal de 70, permițând funcționarea sistemului cu o precizie metrică redusă.

2.2 Estimarea Adâncimilor cu Ajutorul Modelelor AI

Odată stabilit modelul geometric, sarcina centrală devine inferarea adâncimii din imagini monoculare. Lucrarea lui Yang et al. [YKH⁺24], care introduce Depth Anything V2, marchează o schimbare de paradigmă în estimarea adâncimii (MDE). Cercetătorii au demonstrat că datele sintetice, datorită preciziei lor absolute, sunt superioare imaginilor reale etichetate manual pentru învățarea detaliilor geometrice fine. Modelul utilizează o arhitectură de tip profesor-elev (teacher-student), unde un model profesor de mare capacitate generează etichete pseudo-adâncime pe un volum masiv de date reale. Rezultatul este un model care oferă hărți de adâncime cu o robustețe și o granularitate net superioară modelelor anterioare, păstrând în același timp o eficiență computațională ridicată.

Extinzând aceste capacități către o înțelegere multi-vizuală, Depth Anything 3 (DA3) [LCL⁺25] propune o metodă de recuperare a spațiului vizual din orice număr de intrări, indiferent dacă poziția camerei este cunoscută sau nu. Contribuția majoră a DA3 constă în demonstrarea faptului că o arhitectură simplă, bazată pe un transformator standard (vanilla DINO), este suficientă pentru a obține rezultate de ultimă oră fără a fi nevoie de specializări arhitecturale complexe. Prin utilizarea unui target de predicție de tip „depth-ray”, modelul reușește o consistență spațială

remarcabilă, depășind standardele anterioare în acuratețea geometrică și în estimarea poziției camerei cu peste 23% față de predecesorii săi.

2.3 Filtrarea Planului de Mers

În procesarea datelor extrase din mediul vizual, prezența zgomotului și a erorilor sistematice este inevitabilă. Fischler și Bolles [FB81] au introdus algoritmul RANSAC (Random Sample Consensus) ca o soluție pentru potrivirea modelelor matematice pe seturi de date ce conțin un procent ridicat de erori brute (outliers). Spre deosebire de tehnicile de tip „least squares”, RANSAC utilizează un proces iterativ de selecție a unui subset minim de date pentru a genera un model candidat, verificând apoi consensul acestuia cu restul datelor. Această paradigmă este vitală în analiza imaginilor, unde detectorii de trăsături pot genera corespondențe eronate; RANSAC permite izolarea modelului corect (cum ar fi un plan sau o poziție a camerei) prin ignorarea zgomotului care nu se conformează structurii geometrice globale.

2.4 Optimizarea Traectoriilor

În final, având o reprezentare stabilă a spațiului și a obstacolelor, problema deplasării este redusă la găsirea unui drum optim. Hart et al. [HNR68] au oferit baza formală pentru determinarea căilor de cost minim prin algoritmul A*. Acesta utilizează o funcție euristică pentru a ghida procesul de căutare într-un graf, evaluând fiecare nod prin suma dintre costul parcurs de la start (g) și costul estimat până la țintă (h). Autorii demonstrează că dacă euristica h este admisibilă (adică nu supraestimează niciodată costul real), algoritmul A* garantează găsirea căii optime. Această cercetare a stabilit echilibrul matematic între eficiența căutării și certitudinea soluției, rămânând o piatră de temelie pentru orice sistem de navigație care operează în spații de stare complexe.

Capitolul 3

Metodologie

3.1 Arhitectura Generală

Sistemul utilizează o cameră video pentru achiziția de date vizuale în timp real. Deoarece obiectivele camerelor introduc frecvent distorsiuni geometrice (în special spre extremitățile cadrului), este necesară o etapă preliminară de calibrare pentru rectificarea imaginilor. Parametrii de calibrare sunt stocați în sistem, astfel încât procesul nu necesită rulări repetate, deși utilizatorul poate opta pentru o nouă calibrare oricând este necesar.

După captare și rectificare, cadrul video este procesat de un model de estimare monoculară a adâncimii pentru a genera o hartă de adâncime (*depth map*). Următoarea etapă constă în identificarea suprafeței de rulare. În această lucrare, algoritmul de detecție vizează exclusiv planuri orizontale, netede și continue, pe care le vom defini generic sub termenul de „sol”.

În final, integrând datele din harta de adâncime cu geometria planului solului, sistemul stabilește două puncte de referință în spațiul 3D proiectat. Un algoritm de planificare a traseului (*pathfinding*) calculează apoi drumul de lungime minimă între aceste puncte, evitând obstacolele detectate în scenă. Fluxul logic al procesării datelor este sintetizat în diagrama 3.1.

3.2 Caracteristicile Dispozitivelor Hardware Folosite

Dezvoltarea sistemului s-a desfășurat în două etape distincte. Într-o primă fază, implementarea și testarea au fost realizate pe un laptop echipat cu placă grafică dedicată, urmând ca ulterior sistemul să fie adaptat și optimizat pentru a rula pe un dispozitiv cu resurse limitate, respectiv un Raspberry Pi în combinație cu un accelerator neuronal dedicat.

Laptopul utilizat este un Lenovo Legion Pro 5 16IAX10H, echipat cu un procesor




Figura 3.1: Diagrama fluxului de date și a procesării în sistemul de asistență la mobilitate.

Intel Core Ultra 9 275HX, cu 24 de nuclee și o frecvență maximă de 5,40 GHz [Int], și o placă grafică NVIDIA GeForce RTX 5070 Ti Mobile, cu 12 GB memorie VRAM dedicată și un TDP configurabil de până la 140W.

Platforma embedded este reprezentată de un Raspberry Pi 5 cu 8 GB RAM [Rasa], la care s-a atașat modulul Raspberry Pi AI HAT+, un accelerator neuronal cu o putere de procesare de 26 TOPS, bazat pe procesorul Hailo-8 [Rasb]. Implicațiile acestei configurații asupra performanței sistemului, atât avantajele, cât și limitările impuse, sunt discutate în detaliu în secțiunea 3.4, dedicată modelelor monoculare de estimare a adâncimii.

3.3 Calibrarea Camerei

Calibrarea camerei reprezintă un pas esențial în obținerea unor estimări metrice precise ale adâncimii, în special atunci când se utilizează un model monocular metric de estimare a adâncimii. Procesul de calibrare determină parametrii intrinseci ai camerei, distanța focală și punctul principal, precum și coeficienții de distorsiune, care modelează deformările geometrice introduse de lentilă, cel mai frecvent manifestate

la marginile imaginii. Fără corectarea acestor distorsiuni, estimările de adâncime ar acumula erori ce pot afecta semnificativ precizia sistemului de evitare a obstacolelor.

Metoda utilizată se bazează pe tehnica de calibrare propusă de Zhang [Zha00], implementată în biblioteca OpenCV. Aceasta presupune captarea mai multor imagini ale unui panou de calibrare cu model de tablă de șah (*checkerboard*) din unghiuri și distanțe variate, permițând estimarea robustă a parametrilor camerei prin minimizarea erorii de reproiecție.

Algoritmul de calibrare utilizează patru parametri configurabili: `cols`, `rows`, `square_mm` și `min_frames`. Parametrii `cols` și `rows` definesc numărul de colțuri interioare detectabile ale tablei de șah pe orizontală, respectiv verticală. Parametrul `square_mm` specifică dimensiunea reală a laturii unui pătrat, exprimată în milimetri, valoare necesară pentru a stabili corespondența dintre coordonatele din spațiul real și cele din planul imaginii. În fine, `min_frames` indică numărul minim de cadre ce trebuie captate pentru ca estimarea parametrilor să fie suficient de stabilă. Toți acești parametri pot fi ajustați din secțiunea *Settings* a aplicației, oferind flexibilitate în funcție de camera utilizată.

Din punct de vedere tehnic, pentru fiecare cadru în care panoul de calibrare este detectat, algoritmul rafinează pozițiile colțurilor detectate la nivel subpixel folosind metoda `cornerSubPix` din OpenCV, îmbunătățind precizia corespondenței puncte-imagine. Odată acumulate suficiente cadre (`min_frames`), se apelează `cv.calibrateCamera` care returnează matricea intrinsecă a camerei K și vectorul coeficienților de distorsiune d .

Calitatea calibrării este evaluată prin eroarea RMS (*Root Mean Square*) de reproiecție, care măsoară discrepanța medie, în pixeli, între colțurile observate și cele reproiectate pe baza parametrilor estimați. O valoare RMS sub 1.0 este considerată acceptabilă pentru aplicații de tip vedere artificială [Zha00]. În implementarea curentă, dacă valoarea depășește acest prag, utilizatorul este avertizat și recalibrarea este recomandată.

Pentru a evita repetarea procesului de calibrare la fiecare pornire a aplicației, rezultatele sunt persistate într-un fișier `.npz` (format NumPy arhivat), care stochează matricea camerei, coeficienții de distorsiune și valoarea RMS. Numele implicit al fișierului este `calibration.npz`, însă acesta poate fi modificat din secțiunea *Settings*. De asemenea, utilizatorul poate exporta fișierul de calibrare sau poate importa unul existent, cu condiția că acesta a fost generat utilizând aceiași parametri intrinseci și extrinseci.

3.4 Modelul Monocular de Estimare a Adâncimii

Estimarea adâncimii dintr-o singură imagine (estimare monoculară) reprezintă o problemă fundamentală în vederea artificială, cu aplicații directe în navigație autonomă și asistarea persoanelor cu deficiențe de vedere. Spre deosebire de metodele stereoscopice sau LiDAR, abordarea monoculară nu necesită hardware specializat suplimentar, ceea ce o face potrivită pentru sisteme portabile cu resurse limitate.

În cadrul acestui sistem au fost utilizate două modele distincte, selectate în funcție de platforma hardware disponibilă: **Depth Anything 3** pentru platforma NVIDIA și **Depth Anything 2 ViT-S** pentru Raspberry Pi 5 cu acceleratorul AI HAT+.

3.4.1 Depth Anything 3 (Platformă NVIDIA)

Depth Anything 3 [LCL⁺25] reprezintă cea mai recentă iterație a familiei de modele Depth Anything, concepută pentru a depăși limitările versiunilor anterioare în ceea ce privește consistența spațială și generalizarea la scene diverse. În cadrul acestui sistem este utilizată varianta DA3METRIC-LARGE, care produce estimări de adâncime în unități metrice absolute, eliminând necesitatea unei etape suplimentare de scalare relativă.

Modelul este încărcat prin intermediul bibliotecii PyTorch și transferat pe GPU-ul dedicat al laptopului, beneficiind de accelerarea CUDA. Pentru maximizarea performanței, inferența utilizează precizie mixtă automată (*Automatic Mixed Precision* — AMP), care reduce consumul de memorie VRAM și crește debitul de procesare fără a afecta semnificativ precizia rezultatelor. De asemenea, la inițializare se încearcă compilarea statică a modelului prin `torch.compile()`, disponibilă începând cu PyTorch 2.0, care poate aduce îmbunătățiri suplimentare de latență pe hardware compatibil.

Conversia ieșirii brute a rețelei la adâncime metrică se realizează conform formulei oficiale din documentația modelului:

$$d_{\text{metric}} = \frac{f \cdot r}{300} \quad (3.1)$$

unde r reprezintă predicția brută a rețelei (valoare adimensională), iar f este distanța focală medie a camerei, calculată din matricea intrinsecă $\mathbf{K}$ drept $f = (f_x + f_y)/2$. În absența unei calibrări disponibile, distanța focală este estimată pornind de la o presupunere de câmp vizual orizontal de aproximativ 70°, rezultând valori aproximative ale adâncimii metrice.

3.4.2 Depth Anything 2 ViT-S (Platformă Raspberry Pi)

Pentru platforma embedded, utilizarea Depth Anything 3 nu este fezabilă din cauza cerințelor computaționale ridicate ale acestuia și acceleratorului neuronal ce necesită recompilarea modelului special pentru platformă. În schimb, este utilizat modelul **Depth Anything 2** [YKH⁺24] în varianta **ViT-S** (*Vision Transformer Small*), compilat în formatul HEF (*Hailo Executable Format*) specific procesorului Hailo-8 din cadrul modulului AI HAT+. Această compilare este furnizată prin Hailo Model Zoo și permite rularea eficientă a modelului pe NPU-ul dedicat, descărcând complet procesorul ARM al Raspberry Pi-ului de sarcina de inferență.

Pipeline-ul de inferență pe această platformă cuprinde trei etape distincte. În etapa de pre-procesare, cadrul RGB de intrare este redimensionat la rezoluția așteptată de model (518×518 pixeli) și convertit la formatul `uint8 NHWC`, normalizarea fiind gestionată intern de HEF. Inferența propriu-zisă este realizată prin SDK-ul oficial `hailort`, utilizând *virtual streams* pentru comunicarea cu NPU-ul prin interfața PCIe. În etapa de post-procesare, modelul DA2 ViT-S produce o hartă de disparitate inversă (adâncime relativă inversă), în care valorile mai mari corespund obiectelor mai apropiate. Pentru a asigura consistența cu restul pipeline-ului aplicației, unde valorile mai mari de adâncime corespund distanțelor mai mari, harta este inversată și normalizată la intervalul $[0, 1]$ conform relației:

$$d_{\text{norm}} = \frac{d_{\text{max}} - d}{d_{\text{max}} - d_{\text{min}}} \quad (3.2)$$

Această abordare implică o limitare importantă: adâncimile produse pe Raspberry Pi sunt *relative*, nu metrice, ceea ce înseamnă că sistemul nu poate determina distanțele absolute față de obstacole pe această platformă. În consecință, logica de evitare a obstacolelor bazată pe algoritmul A* [HNR68] operează în acest caz cu valori normalizate, iar pragurile de detecție trebuie ajustate corespunzător față de configurația NVIDIA.

3.5 Detecția Solului

Detecția suprafeței solului reprezintă o etapă preliminară esențială pentru algoritmul de evitare a obstacolelor, întrucât permite excluderea zonei practicabile din harta de adâncime înainte de a identifica obstacolele relevante. Fără această etapă, solul însuși ar fi interpretat ca un obstacol, perturbând planificarea traseului. Abordarea adoptată se bazează pe algoritmul RANSAC (*Random Sample Consensus*) [FB81], aplicat în spațiul 3D reconstituit din harta de adâncime și parametrii intrinseci ai camerei.

3.5.1 Proiecția Inversă și Eșantionarea Punctelor Seed

Prima etapă constă în selecția unui subset de puncte candidate pentru estimarea planului solului. Deoarece solul este vizibil cu precădere în zona inferioară a imaginii, algoritmul eșantionează doar o fracțiune configurabilă din partea de jos a hărții de adâncime (parametrul `seed_region`). Pentru a limita costul computațional, se aplică un pas de subșantionare (`stride = 4`), reducând numărul de pixeli evaluați, iar dacă numărul de puncte valide depășește un prag maxim (`max_points = 1500`), se aplică o selecție aleatoare suplimentară.

Fiecare pixel eșantionat este reproiectat din spațiul imaginii în spațiul 3D al camerei folosind relațiile geometrice standard derivate din modelul pinhole al camerei:

$$X = \frac{(u - c_x) \cdot z}{f_x}, \quad Y = \frac{(v - c_y) \cdot z}{f_y}, \quad Z = z \quad (3.3)$$

unde (u, v) sunt coordonatele pixelului, z este adâncimea estimată, iar f_x, f_y, c_x, c_y sunt parametrii intrinseci ai camerei din matricea $\mathbf{K}$.

3.5.2 Estimarea Planului prin RANSAC Vectorizat

Estimarea planului solului se realizează printr-o variantă vectorizată a algoritmului RANSAC [FB81], în care toate iterațiile sunt evaluate în paralel prin operații NumPy, eliminând bucla explicită și reducând semnificativ latența. La fiecare iterație, se selectează aleator câte un triplet de puncte, se calculează normala planului prin produsul vectorial, iar numărul de inlieri (puncte situate la o distanță mai mică decât pragul `threshold` față de plan) este determinat simultan pentru toate iterațiile printr-o operație matricială:

$$\text{dist}(p, \pi) = |\mathbf{n}^T p + d| \quad (3.4)$$

unde $\mathbf{n}$ este vectorul normal al planului și d este termenul liber. Planul cu cel mai mare număr de inlieri este reținut, iar parametrii săi sunt rafinați ulterior printr-o descompunere SVD pe mulțimea completă de inlieri, obținând o estimare mai robustă.

Un plan estimat este acceptat doar dacă componenta verticală a normalei sale depășește un prag configurabil (`normal_threshold`), condiție care asigură că planul detectat este suficient de orizontal pentru a fi considerat sol și nu o suprafață verticală (perete, ușă etc.).

3.5.3 Netezirea Temporală și Construirea Măștii

Pentru a evita fluctuațiile bruște între cadre consecutive, planul estimat la fiecare cadru este combinat cu planul anterior printr-o medie ponderată exponențială:

$$\pi_t = \alpha \cdot \pi_{t-1} + (1 - \alpha) \cdot \pi_{\text{raw}} \quad (3.5)$$

unde α este factorul de netezire (`plane_smoothing`), cu valori apropiate de 1 favorizând stabilitatea temporală în detrimentul reactivității la schimbări rapide ale scenei. Planul rezultat este renormalizat după fiecare actualizare pentru a menține validitatea geometrică a reprezentării.

În final, masca binară a solului este construită direct în spațiul 2D al imaginii, fără a materializa întregul nor de puncte 3D. Pentru fiecare pixel (u, v) , distanța față de planul estimat este calculată vectorizat, iar pixelii a căror distanță este sub pragul `threshold` sunt marcați ca aparținând solului. Pragul în sine este adaptat în funcție de modul de operare al modelului de adâncime: în modul metric se folosește o valoare absolută în metri (`ransac_threshold_metric`), iar în modul relativ pragul este scalat proporțional cu intervalul dinamic al hărții de adâncime curente (`ransac_threshold_relative`).

3.6 Detecția Drumului de Cost Minim

Odată determinată masca binară a solului practicabil, sistemul calculează un drum de cost minim între poziția curentă a utilizatorului și un punct țintă aflat în fața acestuia. Această problemă este formulată ca o căutare de drum pe un graf implicit definit de masca solului, rezolvată prin algoritmul A* [HNR68], cunoscut pentru optimalitatea și eficiența sa în spații de căutare cu euristici admisibile.

3.6.1 Determinarea Punctelor de Start și de Sfârșit

Punctul de start este identificat în zona inferioară a măștii solului, în apropierea centrului orizontal al imaginii, simulând poziția picioarelor utilizatorului în cadrul video. Algoritmul scanează rândurile de jos în sus și, pentru fiecare rând, caută cel mai apropiat pixel de sol față de coloana centrală, extinzând progresiv căutarea spre margini. Punctul de sfârșit este determinat simetric, prin scanare de sus în jos, reprezentând cel mai îndepărtat punct practicabil vizibil în direcția de mers.

Această convenție — start în partea de jos, țintă în partea de sus a imaginii — reflectă direct geometria perspectivei unei camere montate frontal: pixelii din partea inferioară a imaginii corespund suprafețelor apropiate, iar cei din partea superioară corespund zonelor mai îndepărtate.

3.6.2 Algoritmul A* cu Conectivitate 8-Direcțională

Graful de căutare este definit implicit de masca solului: fiecare pixel marcat ca sol reprezintă un nod, iar muchiile conectează fiecare pixel cu cei opt vecini ai săi (conectivitate 8-direcțională). Costul unui pas orizontal sau vertical este 1,0, iar costul unui pas diagonal este $\sqrt{2} \approx 1,4142$, reflectând distanța euclidiană reală dintre pixeli adiacenți.

Funcția euristică utilizată este distanța octilică (*octile distance*), care constituie o euristică admisibilă pentru conectivitatea 8-direcțională:

$$h(n, g) = \max(\Delta r, \Delta c) + (\sqrt{2} - 1) \cdot \min(\Delta r, \Delta c) \quad (3.6)$$

unde $\Delta r = |r_n - r_g|$ și $\Delta c = |c_n - c_g|$ sunt diferențele de rând și coloană dintre nodul curent n și nodul țintă g . Admisibilitatea euristicii garantează că A* returnează întotdeauna drumul de cost minim [HNR68].

Algoritmul menține o coadă de priorități (*min-heap*) ordonată după scorul $f = g + h$, unde g reprezintă costul acumulat de la start, și o matrice g_score de dimensiunea imaginii pentru stocarea celui mai bun cost cunoscut pentru fiecare nod. La finalizare, drumul este reconstruit prin urmărirea înapoi a structurii `came_from` de la nodul țintă până la cel de start.

Dacă nu există nicio cale continuă de pixeli de sol între punctul de start și cel de sfârșit — situație posibilă când un obstacol blochează complet trecerea — algoritmul returnează un drum vid, iar sistemul poate semnaliza utilizatorul în consecință.

Capitolul 4

Arhitectura Aplicației

4.1 Prezentare Generală

Aplicația este structurată ca un sistem modular de procesare video în timp real, cu scopul de a detecta planul solului și de a planifica o traiectorie navigabilă pe baza unei hărți de adâncime generate de un model de învățare profundă. Sistemul suportă două profiluri hardware distincte: un host cu GPU NVIDIA, folosind PyTorch și CUDA pentru inferență, respectiv un Raspberry Pi 5 cu accelerator NPU Hailo-8, folosind biblioteca `hailort`. Indiferent de profilul activ, restul pipeline-ului rămâne identic, ceea ce face posibilă portabilitatea codului fără modificări.

Întreaga bază de cod este scrisă în Python 3.11+ și organizată în două mari componente: un **backend** de procesare și o **interfață grafică** (GUI) construită cu PyQt6. Separarea clară dintre aceste două componente permite înlocuirea sau testarea fiecăreia independent.

4.2 Principii de Proiectare Utilizate

4.2.1 Separarea Responsabilităților

Fiecare modul al aplicației are o singură responsabilitate bine definită. Modulul `config.py` se ocupă exclusiv de citirea și validarea configurației. Modulul `hardware.py` abstractizează diferențele dintre platformele hardware. Modulul `ground.py` conține exclusiv logica de detectare a planului solului, fără nicio referință la interfața grafică sau la camera video. Această separare face ca fiecare componentă să poată fi testată, înlocuită sau extinsă fără a afecta restul sistemului.

4.2.2 Programare Orientată pe Obiecte

Clasele sunt folosite acolo unde există stare internă care trebuie gestionată pe durata vieții unui obiect. `HardwareProfile` încapsulează profilul hardware activ și expune proprietăți derivate (`is_nvidia`, `is_rpi`, `is_metric`) fără a expune câmpurile interne. `CalibrationService` grupează operațiile de calibrare împreună cu configurația de care au nevoie. `DepthPipeline` gestionează întregul ciclu de viață al procesării unui cadru video: deschiderea camerei, încărcarea modelului, firul de captură, și eliberarea resurselor la oprire. `ModelRegistry` abstractizează alegerea backend-ului de inferență, astfel că apelantul nu știe și nu trebuie să știe dacă inferența rulează pe CUDA sau pe NPU Hailo.

Funcțiile pure sunt preferate claselor atunci când nu există stare internă de gestionat. Modulele `ground.py`, `path.py` și `visualization.py` sunt compuse exclusiv din funcții, deoarece transformările pe care le realizează (proiecție 3D, RAN-SAC, A^* , suprapunere vizuală) sunt fără efecte secundare și nu necesită obiecte.

4.2.3 Configurație Tipizată

Configurația aplicației este citită o singură dată la pornire din fișierul `config.toml` și transformată într-un arbore de `dataclass-uri` imutabile (`frozen=True`): `AppConfig`, `CameraConfig`, `CalibrationConfig`, `GroundConfig` etc. Această abordare elimină accesul prin chei de tip șir de caractere (de exemplu `cfg["ground"]["seed_region"]`) și înlocuiește șirul de caractere cu attribute tipizate (`cfg.ground.seed_region`), ceea ce permite detectarea erorilor de configurare la încărcare, nu la rulare, și oferă autocompletare în mediile de dezvoltare.

4.2.4 Comunicare Asincronă prin Semnale Qt

Inferența modelului de adâncime și captura video rulează în fire de execuție separate față de firul principal al interfeței grafice. Comunicarea dintre fire se realizează exclusiv prin mecanismul de semnale și sloturi al Qt (`pyqtSignal`), care garantează că actualizările interfeței grafice au loc întotdeauna pe firul principal. Această abordare previne blocarea interfeței în timpul procesării și elimină condițiile de cursă (*race conditions*) specifice accesului concurent la widget-uri.

4.2.5 Inversiunea Dependențelor la Nivel de Backend

Modulul `model.py` acționează ca un registru de factory: în funcție de profilul hardware activ, deleghează apelurile fie către `model_nvidia.py`, fie către `model_rpi.py`. Pipeline-ul central (`pipeline.py`) depinde exclusiv de interfața abstractă a lui

`ModelRegistry`, nu de implementările concrete. Adăugarea unui nou backend (de exemplu un alt accelerator hardware) necesită doar adăugarea unui fișier nou și a unui caz în registru, fără a modifica pipeline-ul sau GUI-ul.

4.3 Arhitectura pe Straturi

Aplicația este organizată în patru straturi distincte, cu dependențe strict direcționate de sus în jos. Stratul superior depinde de cel imediat inferior; niciun strat nu cunoaște existența straturilor superioare.

4.3.1 Stratul de Prezentare (GUI)

Corespunde pachetului `gui/` și este responsabil exclusiv de interacțiunea cu utilizatorul. Conține:

- `app.py` — fereastra principală (`MainWindow`), care gestionează navigarea între ecrane printr-un `QStackedWidget`;
- `main_menu.py` — ecranul de pornire cu cele patru acțiuni principale;
- `calibration.py` — ecranul de calibrare, inclusiv dialogul modal cu vizualizare live și afișarea scorului RMS;
- `settings.py` — formularul de editare a configurației, cu scriere înapoi în `config.toml`;
- `system_view.py` — vizualizarea live a sistemului, cu bara laterală de opțiuni și redarea cadrelor procesate;
- `components.py` — widget-uri reutilizabile: `StyledButton`, `NavBar`, `ToggleSwitch`, `SectionHeader`, `StatusBadge`;
- `styles.py` — paleta de culori, fonturile și foaia de stiluri globală Qt.

Stratul de prezentare nu realizează nicio procesare de imagine sau inferență. El pornește și oprește pipeline-ul prin metode publice și primește rezultate prin semnale Qt.

4.3.2 Stratul de Orchestrare (Pipeline)

Corespunde modulului `pipeline.py` și reprezintă punctul central de coordonare al aplicației. Clasa `DepthPipeline` gestionează:

- un fir de captură dedicat, care citește continuu cadre de la cameră și păstrează întotdeauna cel mai recent cadru disponibil;
- un fir de inferență, care consumă cadrele, rulează pipeline-ul complet și emite rezultate prin semnale Qt;
- starea internă a sistemului: hărțile de corecție a distorsiunii, matricea intrinsecă activă, planul anterior detectat.

Rezultatul unui cadru procesat este reprezentat de dataclass-ul `FrameResult`, care agregă cadrul RGB, harta de adâncime, masca solului, traiectoria A*, punctele de start/stop și coeficienții planului.

4.3.3 Stratul de Procesare (Core)

Conține implementările algoritmice independente de hardware și de interfața grafică:

- `ground.py` — detectarea planului solului prin RANSAC vectorizat cu eșantionare subpixelică, urmat de rafinare SVD și construirea măștii direct în spațiul 2D al imaginii;
- `path.py` — planificarea traiectoriei prin algoritmul A* cu conectivitate pe 8 direcții și euristică octilă admisibilă;
- `visualization.py` — suprapunerea vizuală a măștii solului, a traiectoriei și a barei de stare pe cadrul video;
- `camera.py` — deschiderea camerei (V4L2 sau picamera2), construirea hărților de corecție a distorsiunii și aplicarea lor;
- `calibration.py` — captarea pozelor de calibrare și rezolvarea matricei intrinseci prin `cv2.calibrateCamera`.

4.3.4 Stratul de Infrastructură

Conține modulele care nu realizează procesare propriu-zisă, ci furnizează configurație, abstractizare hardware și acces la modele:

- `config.py` — citirea fișierului `config.toml` și construirea arborelui de dataclass-uri tipizate;
- `hardware.py` — `HardwareProfile`: abstractizarea profilului activ și selecția dispozitivului de calcul;

- `model.py` — `ModelRegistry`: factory care deleghează încărcarea și inferența modelului de adâncime;
- `model_nvidia.py` — backend PyTorch + CUDA, folosind `DepthAnything3` cu AMP și `torch.compile` opțional;
- `model_rpi.py` — backend Hailo, folosind `hailort` pentru inferența pe NPU-ul Hailo-8;
- `main.py` — punctul de intrare în aplicație; lansează GUI-ul sau modul headless.

4.4 Diagrama Straturilor




Figura 4.1: Arhitectura pe straturi a aplicației. Dependentele sunt direcționate exclusiv de sus în jos.

4.5 Fluxul de Date

La pornirea sistemului, `MainWindow` încarcă configurația tipizată din `config.toml` printr-un apel la `AppConfig.load()`. Când utilizatorul apasă butonul *START* din ecranul de vizualizare live, `SystemViewWidget` instanțiază un `DepthPipeline` și pornește firul de inferență. Acesta inițializează `ModelRegistry` (care, în funcție de profilul hardware, încarcă fie modelul PyTorch, fie fișierul HEF pentru Hailo), deschide camera prin `CameraFactory` și pornește firul de captură.

La fiecare cadru disponibil, pipeline-ul aplică corecția de distorsiune, rulează inferența pentru a obține harta de adâncime, detectează planul solului prin RANSAC vectorizat și construiește masca, planifică traiectoria prin A*, și împachetează

toate rezultatele într-un obiect `FrameResult`. Acesta este transmis stratului de prezentare prin semnalul `Qt_result_signal`, unde `SystemViewWidget` aplică suprapunerile vizuale și actualizează widget-ul de afișare.

Utilizatorul poate modifica parametrii sistemului în orice moment prin ecranul *Settings*, care scrie valorile actualizate înapoi în `config.toml` și semnalizează ferestrei principale să reîncarce configurația. Modificările intră în vigoare la următoarea pornire a pipeline-ului.

Capitolul 5

Rezultate

Dat fiind faptul că nu există teste specifice care să încorporeze în totalitate un asemenea sistem, vom testa fiecare componentă individual, și vom discuta situațiile în care acestea excelează, dar și situații în care apar probleme. La final vom discuta despre aportul fiecărei componente asupra latenței și despre aceasta în general, în funcție de sistem. Se vor face și comparații între sistemul ce folosește placa grafică dedicată NVIDIA, și acceleratorul HAILO-8.

5.1 Calibrarea Camerei

Rezultatele din urma calibrării sunt calculate în funcție de metrica „RMS reprojection error” și sunt puternic influențate de modul în care utilizatorul mișcă modelul de tablă se șah în cadru, și unghiul la care acest este expus. Un scor mai mic reprezintă o calibrare mai performantă, și invers, un scor mare reprezintă o calibrare defectuoasă. Cu cât cadrele sunt capturate în poziții și unghiuri cât mai diverse, cu atât rezultatele vor fi mai bune. Sistemul recomandă captarea a minim 20 de cadre, însă utilizatorul are libertatea de a seta manual, din secțiunea de setări, numărul de cadre ce vor fi captate.

În această secțiunea vom utiliza un grid de 6x9, cu lungimea laturii unui pătrat de 18 milimetrii, și 20 de cadre auto-capturate. Vom testa un scenariu în care calibrarea se va face

5.2 Aproximarea Adâncimii

5.3 Detecția Planului

5.4 Determinarea Drumului de Cost Minim

5.5 Latență

5.6 Lumină Abundentă vs. Redusă

Capitolul 6

Direcții viitoare și Concluzii

Concluzii ...

Bibliografie

- [B⁺21] Rupert R. A. Bourne et al. Causes of blindness and vision impairment in 2020 and trends over 30 years, and prevalence of avoidable blindness in 2020: a systematic review and meta-analysis. *The Lancet Global Health*, 9(2):e144–e160, 2021.
- [FB81] Martin A. Fischler and Robert C. Bolles. Random sample consensus: a paradigm for model fitting with applications to image analysis and automated cartography. *Commun. ACM*, 24(6):381–395, June 1981.
- [HNR68] Peter E. Hart, Nils J. Nilsson, and Bertram Raphael. A formal basis for the heuristic determination of minimum cost paths. *IEEE Transactions on Systems Science and Cybernetics*, 4(2):100–107, 1968.
- [Int] Intel Corporation. Intel core ultra 9 processor 275hx – product specifications. <https://www.intel.com/content/www/us/en/products/sku/242293/intel-core-ultra-9-processor-275hx-36m-cache-up-to-5-40-ghz/specifications.html>. Accesat: mai 2025.
- [Int23] International Guide Dog Federation. Annual statistics report on global guide dog mobility. Technical report, IGDF, 2023.
- [LCL⁺25] Haotong Lin, Sili Chen, Junhao Liew, Donny Y Chen, Zhenyu Li, Guang Shi, Jiashi Feng, and Bingyi Kang. Depth anything 3: Recovering the visual space from any views. *arXiv preprint arXiv:2511.10647*, 2025.
- [Rasa] Raspberry Pi Ltd. Raspberry pi 5 – product brief. <https://www.raspberrypi.com/products/raspberry-pi-5/>. Accesat: mai 2025.
- [Rasb] Raspberry Pi Ltd. Raspberry pi ai hat+ – product brief. <https://www.raspberrypi.com/products/ai-hat/>. Accesat: mai 2025.
- [S⁺18] G. Stevens et al. Barriers to accessing assistive technology for people with visual impairment. *Disability and Rehabilitation*, 40, 2018.

- [S⁺21] J. D. Steinmetz et al. Causes of blindness and vision impairment in 2020 and trends over 30 years. *Scientific Reports (Nature)*, 2021.
- [Wor19] World Health Organization. *World report on vision*. WHO Press, Geneva, 2019.
- [YKH⁺24] Lihe Yang, Bingyi Kang, Zilong Huang, Zhen Zhao, Xiaogang Xu, Jiashi Feng, and Hengshuang Zhao. Depth anything v2. *Advances in Neural Information Processing Systems*, 37:21875–21911, 2024.
- [Zha00] Zhengyou Zhang. A flexible new technique for camera calibration. *IEEE Transactions on pattern analysis and machine intelligence*, 22(11):1330–1334, 2000.